大数据时代下的铁路客运量影响因素统计分析

摘要

近年来，铁路建设在“十四五”计划的支持下稳步前进，大数据与人工智能等技术的发展加快了铁路的数字化建设，加上中国国家铁路集团有限公司的持续投入和努力，2023年全国铁路客运量创下新高：发送客36.8亿次，高峰日突破200万次。这也意味着，铁路作为一种较为便利的交通工具，已经成为大部分居民优先的方式，也标志着中国铁路客运市场的繁荣发展。可见，铁路客运量是铁路发展水平的一重要评判标准。

为研究铁路客运量的影响因素，本文从RESSET宏观经济数据库、RESSET行业数据库中调用了全国多个行业以及铁路客运量的年数据，在进行预处理后，通过灰色关联度加以筛选处理后，留下了八个因素进行后续研究。我们尝试适用支持向量回归、岭回归、逐步回归三种模型进行拟合，经过MSE误差分析后，我们选用误差最小的逐步回归得到的模型进行深入分析，并根据本次研究结果提出建议。

关键词：铁路客运量；宏观经济数据库；灰色关联度；支持向量回归；岭回归；逐步回归；MSE误差

目录

摘要.....I
表格与插图清单.....II
一、绪论.....6
（一）研究背景与意义.....6
1.研究背景.....6
2.理论意义.....6
3.实践意义.....6
（二）国内外研究现状.....6
二、基础模型.....6
（一）Newton插值法.....6
1.理论基础.....6
2.插值公式.....6
（二）灰色关联分析.....7
1.理论基础.....7
2.建模步骤.....7
（三）格兰杰因果检验.....8
1.理论基础.....8
2.检验步骤.....9
（四）ADF检验.....10
1.理论基础.....10
2.检验步骤.....10
（五）支持向量回归（SVR）.....11
1.理论基础.....11
2.计算步骤.....11
（六）岭回归（Ridge Regression）.....13
1.理论基础.....13
2.计算公式.....13

（七）逐步回归.....14
三、铁路客运量影响因素指标的选取和量化.....14
（一）指标选取.....14
（二）数据预处理.....17
（三）因果检验.....19
（四）平稳性检验.....19
四、铁路客运量影响因素的关联模型建立.....21
（一）基于支持向量回归的关联模型.....21
（二）基于岭回归的关联模型.....24
（三）基于逐步回归的关联模型.....26
（四）关联模型的总结分析.....29
五. 铁路发展建议.....30
六. 研究不足.....31
参考文献.....32
附录.....34
致谢.....49

表格与插图清单

表1 影响指标与铁路客运量关联程度

表2 选取指标预处理后的数据

表3 三种回归模型的误差对比表（MSE）

图1 灰色关联分析的步骤及公式

图2 SVR示意图

图3 格兰杰因果检验下的过拟合状态

图4 针对每个数据序列的稳定性检验结果

图5将所有数据作为训练集的拟合效果散点图

图6 将数据按4:1分成训练集和测试集的拟合效果散点图

图7 将数据按4:1分成训练集和测试集的拟合偏差计算值

图8 将所有数据作为训练集的拟合偏差计算值

图9 岭回归下真实值与预测值拟合图

图10 岭回归下MSE误差图

图11 最佳模型

图12 最佳模型下特征量对应模型参数及误差结果（MSE）

图13 前向逐步回归真实值与预测值拟合图

图14 后向逐步回归真实值与预测值拟合图表4 三种回归模型的误差对比表（MSE）

大数据时代下的铁路客运量影响因素统计分析

一．绪论

（一）研究背景与意义

1.研究背景

铁路运输不仅对经济发展和社会连通起着至关重要的作用，对环境保护和国家安全也具有重要意义。本论文旨在通过大数据统计研究影响铁路客运量的各方面影响因素，并运用各种模型计算其影响权重，进行未来客运量的预测。

2.理论意义

铁路客运作为一种普遍的交通方式，其客流量受到多种因素的影响。传统观点认为，客流量主要受个人消费倾向等主观因素的制约。然而，铁路客运量实际上与经济、社会、文化等多方面因素密切相关。作为拉动经济发展的重要因素之一，铁路客运在人民生活中的地位日益突出。

因此，我们需要一个综合考虑经济、社会、文化等多方面因素的模型，以准确预测铁路客运量。在这种研究中，"回归"成为一种常用的统计分析方法，用于探索变量之间的关系，并预测一个或多个因变量（或称为目标变量）与一个或多个自变量（或称为预测变量）之间的关系。

本文根据数据特征，采用了基于向量回归、岭回归和逐步回归等三种回归模型进行拟合比较。通过分析均方误差（MSE），选取了三个模型中拟合效果最佳的模型，以实现对铁路客运量的准确预测。

3.实践意义

铁路客运是国家交通体系中不可或缺的重要组成部分，对经济和民生都有着巨大影响。因此，铁路客运量的预测模型具有重要的实践意义。首先，这些模型可以帮助我们判断不同因素对铁路客运量的贡献权重，从而制定针对性的政策措施。其次，我们可以将全国模型应用于特定地区，分析地区驱动铁路客运的弱势因素，并有针对性地推动地区发展。此外，根据铁路客运预测结果，我们还能够针对存在缺陷的铁路基础设施进行有针对性的改进，减轻基础设施的负荷，并

提升应对突发情况的能力。

（二）国内外研究现状

目前，许多国内外学者都对铁路客运量预测方法进行了研究。Li等选择采用灰色模型进行年预测，并结合月比例系数计算月客运量。李晓东在各种客运量预测模型的基础上，选择对线性回归模型的结果，利用马尔可夫链改进，提高了客运量预测的准确性。林璐则将各种影响因素作为输入，客运量作为响应，通过自回归综合移动平均模型(ARMIMA)，提高了预测的精确度。Milenković等选择季节性差分自回归滑动平均模型(SARIMA)对月客运量进行预测，也取得了良好的预测结果。Bougas C(2013)适用指数平滑法、调和回归等多个时间序列模型对航空客运量进行短期和中期预测，结果证明时间序列都具有较好的预测能力。Niu和Sum选择灰色GM(1,1)模型预测客运量发展趋势，结果发现该模型虽然在时间序列分析上效果较优，但在反映波动性数据上存在困难。

随着人工智能的不断发展，机器学习为铁路客运量预测提供了更多可能性。王卓等在附加动量法的基础上引入动量因子，避免神经网络陷入局部极小值，并引入自适应学习，得到改进后的BP神经网络，其预测结果优于标准神经网络。李万等先采用粒子群算法(IPSO)对LSTM的神经元数量、学习率、迭代次数等超参数进行优化，建立了IPSO-LSTM预测模型，其具有更高的精度。

其中汪志红等人主要研究干预性季节因素和突发事件对客运量的影响，且提出了适应中国铁路客运量的三时段春节季节调整的ARIMA预测模型。常振海等人提出了铁路客运量的季节时间序列模型，谭玉顺等人针对长三角地区研究了客运量影响因素并运用了灰色关联分析。李静仪提出VAR模型和回归分析法进行客运量预测。肖尧等人则提出了基于Prophet模型的铁路客运量需求分析方法和基于Seq2Seq-At-tention与Prophet非线性组合模型的短期客流预测方法。秦进等人则提出高速铁路日常客运量的EMD-Informer组合预测方法。

目前国内对铁路客运量影响因素的研究主要集中在季节时间，人口增长率，突发性事件如新冠疫情，国民经济水平和铁路运营里程等因素方面，并针对性地建立季节时间序列模型和BP神经网络模型，运用灰色关联分析影响因素权重并用回归分析法研究预测精度。

由于本文研究的数据库样本体量较小，不足以达到机器学习所需要的数据

量，因此本文选择了支持向量回归、岭回归、逐步回归三种回归方式进行拟合。

二. 基础模型

（一）Newton插值法

1.理论基础

Newton 插值法是一种用于在给定一组数据点的情况下，估计出一个多项式来近似地表示这些数据点的方法。它可以用于估计未知数据点的值，或者在数据点之间进行平滑地近似。将 Newton 插值法应用于铁路客运量部分年份数据缺失问题，此方法的基本思路为：给定一组历年铁路客运量数据，其中部分年份数据缺失，插值（时间）节点设为x_i。函数y=f(x)表示已知铁路客运量随插值节点的某种内在规律的数量关系。为挖掘其规律，根据已知的客运量数据序列构造既能反映f(x)特性又便于计算的简单函数P(x)，用P(x)近似表示插值节点为x的f(x)。此时，P(x)为构造的铁路客运量插值多项式。[1]

2.插值公式

$$P(x) = a_0 + a_1(x - x_0) + a_2(x - x_0)(x - x_1) + \ldots + a_n(x - x_0)\ldots(x - x_{n-1}) \tag{1-1}$$

式中:$a_0, a_1, \ldots, a_n$为待定系数；x_0, x_1, x_{n-1}为数据序列的n个插值节点，x是需要估计的插值节点，P(x)为构造的插值多项式的铁路客运量估计函数。

为方便求解a_k(k=0,1,2,...,n),有以下定义：[1]

①定义1：

一阶差商是两个数据点之间的斜率，而更高阶的差商则是基于较低阶差商的计算得出的。$f[x_0, x_k]=\frac{f(x_k)-f(x_0)}{x_k-x_0}$为f(x)关于点$x_0$，$x_k$一阶差商；$f[x_0, x_1, x_k]=\frac{f[x_0,x_k]-f[x_0,x_1]}{x_k-x_0}$为f(x)关于点$x_0, x_1, x_k$二阶差商；以此类推，$f[x_0, x_1, \ldots, x_k]=\frac{f[x_0,x_1,\ldots,x_k]-f[x_0,x_1,\ldots,x_{k-1}]}{x_k-x_{k-1}}$为k阶差商。

②差商的基本性质：

$$f[x_0, x_1, \ldots, x_k] = \frac{f[x_0, x_1, \ldots, x_k] - f[x_0, x_1, \ldots, x_{k-1}]}{x_k - x_{k-1}} \tag{1-2}$$

当$x=x_k$时，经推导得：

$$a = f[x_0, x_1, \ldots, x_k] \quad k = 0, 1, \ldots, n \tag{1-3}$$

由(1-1)和(1-3)可得

$$P(x) = f(x_0) + f[x_0, x_1](x - x_0) + f[x_0, x_1, x_2](x - x_0)(x - x_1) + \ldots + f[x_0, x_1, \ldots, x_n](x - x_0)\ldots(x - x_{n-1}) \quad (1\text{-}4)$$

（二）灰色关联分析

1. 理论基础

灰色关联分析是一种通过探测数据之间的相关性来评估它们之间关联程度的方法。它常用于处理数据不完备或者不确定性较高的情况下。在灰色关联分析中，首先将数据序列进行归一化处理，然后计算各序列之间的关联度，最后根据关联度大小进行排序和评估。

2. 建模步骤

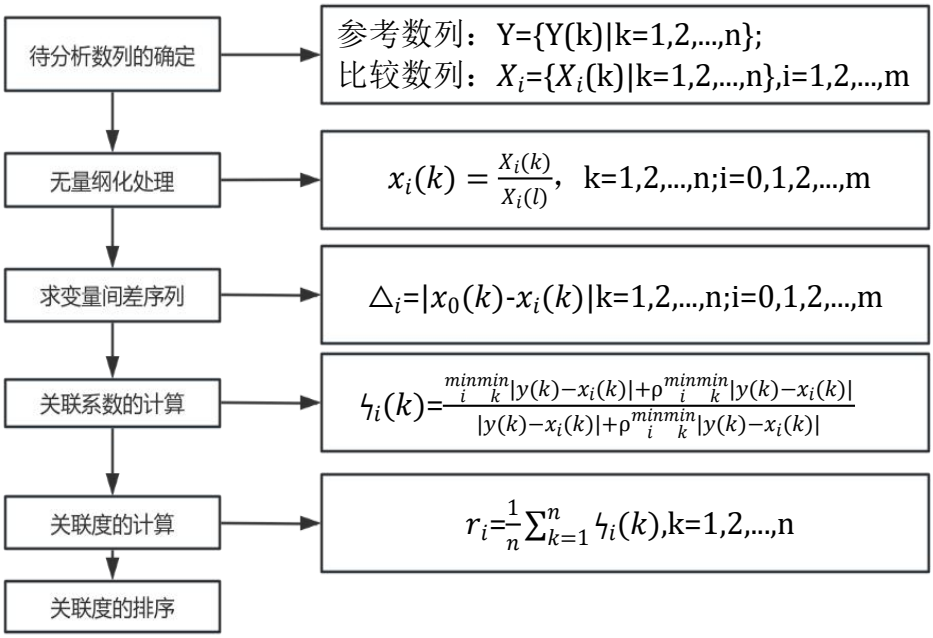

图1 灰色关联分析的步骤及公式

（三）格兰杰因果检验

1. 理论基础

格兰杰因果检验是一种时间序列分析方法，用于判断一个时间序列是否能够

“因果”另一个时间序列的变化。在格兰杰因果关系中，我们关注的是一个变量（称为因变量）是否能够被另一个变量（称为自变量）的过去值预测得更好。如果自变量的过去值可以提供关于因变量未来值的额外信息，就可认为自变量“格兰杰因”于因变量。

格兰杰因果检验通过比较加入潜在因果变量后的模型与只包含因变量自身滞后值的模型，以及对潜在因果变量的滞后期系数进行统计检验，来验证两个变量之间是否存在因果关系。此方法涉及到向量自回归模型（VAR）和因果推断。

①向量自回归模型：

在一个向量自回归模型中，多个时间序列变量被同时建模，每个变量的当前值被其过去值及其他变量的过去值所解释。

针对多元时间序列数据$\mathrm{X,Y} \in \mathrm{R}^{\mathrm{N*T}}$，对于任意第t个时间间隔，存在如下的线性表达式：

$$x_t = \sum_{k=1}^{d} A_{x|x,k} x_{t-k} + \sum_{k=1}^{d} A_{x|y,k} y_{t-k} + \epsilon_{xyt} \tag{2-1}$$

$$y_t = \sum_{k=1}^{d} A_{y|x,k} x_{t-k} + \sum_{k=1}^{d} A_{y|y,k} y_{t-k} + \epsilon_{xyt} \tag{2-2}$$

其中A_k为自回归系数（通常以最小二乘法来估计），$A_k \in \mathrm{R}^{\mathrm{N*N}}, \mathrm{k} = 1,2,\ldots,d$是向量自回归模型的阶数，$\epsilon_{xyt}$是与模型相关残差。残差的方差表示式为：[2]

$$V_{x|\bar{x},\bar{y}} = var(\epsilon_{xy}) \tag{2-3}$$

$$V_{y|\bar{x},\bar{y}} = var(\epsilon_{yx}) \tag{2-4}$$

其中，$x|\bar{x},\bar{y}$是运用x_t，y_t的过去值对x_t的预测。因此，从y到x(y预测x)的格兰杰因果关系为：

$$\mathrm{GC}_{\mathrm{y\to x}} = \ln\left(\frac{V_{x|\bar{x}}}{V_{x|\bar{x},\bar{y}}}\right) \tag{2-5}$$

其中，$V_{x|\bar{x}}$为自己对自己的预测所得方差，$V_{x|\bar{x},\bar{y}}$为加入y后，过去的y和x一起对x的预测所得方差。$0 \le \mathrm{GC}_{\mathrm{y\to x}} < \infty$,当$\mathrm{GC}_{\mathrm{y\to x}} > 0$时，表示加入y后，其预测所得方差小于只有x参与预测时的方差，说明y到x有格兰杰因果关系。[2]

2.检验步骤

①建立向量自回归模型：建立一个包含了所有待分析的时间序列变量的向量自回归(VAR)模型,其中每个变量的当前值被其自身的滞后值和其他变量的滞后值所解释。

②估计因变量被自身滞后值解释的程度.

③引入其他变量的滞后值作为潜在因果变量，观察其对因变量解释程度的影响。

④比较加入潜在因果变量后的模型与仅含因变量滞后值的模型的拟合程度，评估因果关系可能性。如果加入潜在因果变量后因变量的解释程度显著提高，即可得出因果关系可能存在的初步结论。

⑤统计检验潜在因果变量的滞后期系数，若潜在因果变量的滞后期系数在统计上显著不为零，则确认其显著性来确定因果关系的存在。

总之，格兰杰因果检验建立在向量自回归模型和因果推断的基础之上。通过比较不同模型的拟合优度，判断一个时间序列是否能够因果于另一个时间序列的变化。但需要注意的是，格兰杰因果检验只能检验两个变量之间的因果关系，并不能判断真实的因果关系，因为在现实中，变量之间的因果关系可能受到其他未被考虑的因素的影响。

（四）ADF检验

1.理论基础

ADF（Augmented Dickey-Fuller）检验是一种用于检验时间序列数据是否具有单位根的统计检验方法。单位根表示数据序列具有非平稳性，即均值和方差可能随时间变化而不稳定。

ADF检验的基本假设是：原假设（H_0）是数据序列具有单位根，即非平稳性；备择假设（H_1）是数据序列不具有单位根，即是平稳的。

ADF检验的原理是利用单位根检验统计量来比较数据序列的实际值与预期值之间的关系。如果检验统计量的值小于对应的临界值，就可以拒绝原假设，即认为数据序列是平稳的；反之，则不能拒绝原假设，即认为数据序列具有单位根，是非平稳的。

2.检验步骤

①建立假设：

原假设（Null Hypothesis，H_0）：时间序列数据具有单位根，即是非平稳的。备择假设（Alternative Hypothesis，H_1）：时间序列数据不具有单位根，

即是平稳的。

②选择滞后阶数：

对于ADF检验，通常需要选择一个适当的滞后阶数。滞后阶数指的是时间序列自身的延迟数量，用于构建差分序列，以检验单位根的存在性。选择滞后阶数的常见方法包括观察自相关图（ACF）和偏自相关图（PACF），以及使用信息准则（如AIC、BIC）进行模型选择。

③计算ADF统计量：

使用选定的滞后阶数，计算ADF统计量。ADF统计量的计算通常基于一个线性回归模型，该模型包括时间序列本身及其滞后值。ADF统计量的计算包括考虑了数据的一阶差分，以消除序列的线性趋势。

④确定临界值：

确定所选显著性水平（通常为5%或1%）下的临界值，以便与计算出的ADF统计量进行比较。

⑤做出决策：

将计算得到的ADF统计量与临界值进行比较。如果ADF统计量小于临界值，则拒绝原假设，即认为时间序列是平稳的；如果大于临界值，则不能拒绝原假设，即认为时间序列具有单位根，是非平稳的。最后根据对原假设的接受或拒绝，做出相应的结论，并对时间序列的性质进行解释。

（五）支持向量回归（SVR）

1.理论基础

支持向量回归（Support Vector Regression，SVR）是一种基于支持向量机（Support Vector Machine，SVM）的回归算法，用于解决回归问题。与传统的回归方法相比，SVR 不仅能够处理线性问题，还可以有效地处理非线性问题。

SVR 的基本思想是利用支持向量机的核心概念，通过寻找一个最优的超平面（或曲面），使得该超平面与训练数据之间的间隔最大化，并且超平面与尽可能多的训练数据点保持在一定的容忍范围内。

SVR 的关键思想包括以下几点：

①间隔最大化：SVR 在训练过程中尝试找到一个超平面，使得该超平面与训

练样本之间的间隔最大化。这种间隔通常被称为“边界”，SVR试图使边界内的点尽可能接近超平面，同时使边界之外的点远离超平面。

②损失函数：SVR 使用损失函数来衡量预测值与实际值之间的差异。常用的损失函数包括ε-insensitive loss函数，它允许一定程度的误差(ε)存在，只有超出这个误差范围的样本才会被算作损失。

③核技巧：与支持向量机一样，SVR 可以利用核函数来将数据从原始空间映射到高维特征空间，从而使得非线性问题也可以被处理。常用的核函数包括线性核、多项式核和径向基函数（RBF）核。

④正则化参数：SVR 中通常包含一个正则化参数（C），用于控制模型的复杂度，防止过拟合。正则化参数C越小，模型对误差的容忍度越高，反之则越低。

2.计算步骤

①数据预处理：首先，需要对输入的训练数据进行预处理。这包括数据清洗、特征选择、特征缩放等操作，以确保数据质量和可用性。

②选择核函数：SVR 在训练过程中使用核函数来将数据从原始空间映射到高维特征空间。常用的核函数有线性核、多项式核和径向基函数（RBF）核。根据问题的特性和数据的分布选择合适的核函数。

③VR的目标是寻找一个最优的超平面，使得训练数据点尽可能接近该超平面，并且在一定容忍范围内。因此，SVR的训练过程可以转化为一个优化问题。通常采用的优化问题形式为最小化损失函数加上正则化项。如：

$$min_{w,b,\xi^{\vee},\xi^{\wedge}}\ \frac{1}{2}||w||^2 + C\sum_{i=1}^{N}(\xi_i^{\vee} + \xi_i^{\wedge})$$

④求解优化问题： 通过数学优化方法（如凸优化算法）来求解构建的优化问题，以找到最优的超平面参数(w)和(b)。

⑤模型评估和调优： 使用训练数据集训练得到的模型，通过评估指标（如均方误差、R^2分数等）来评估模型的性能。根据评估结果可以调整超参数（如正则化参数C、核函数的参数等），进一步优化模型性能。

⑥预测： 使用训练好的SVR模型对新的未知数据进行预测，得到回归结果。

$$min\frac{1}{2}||w||^2 \tag{3-1}$$

$$s.t.|y_i - (wx_i + b)| \le \varepsilon，\forall i \tag{3-2}$$

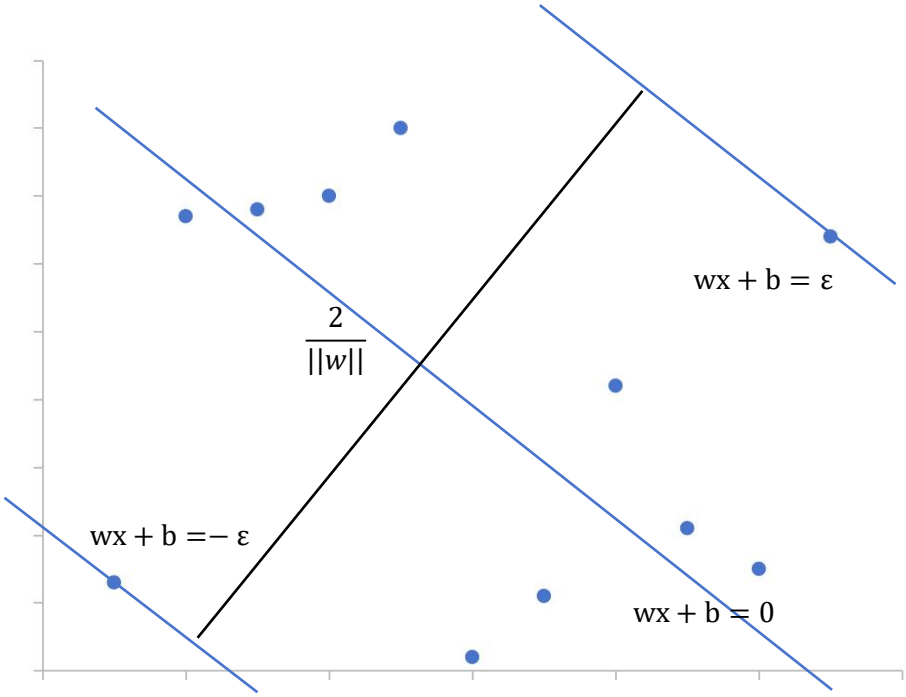

使得到超平面最远样本点的“距离”最小

图2 SVR示意图

（六）岭回归（Ridge Regression）

1.理论基础

岭回归是一种线性回归方法，旨在解决普通最小二乘法中存在的多重共线性问题。在普通最小二乘法中，如果数据集中的自变量之间存在高度相关性，就会导致参数估计不稳定甚至无法求解。岭回归通过引入一个正则化项（岭项），在目标函数中加入这一项，从而在最小化残差平方和的同时，限制模型参数的增长，进而减小参数估计的方差，提高模型的泛化能力。其基本原理为：

①目标函数：岭回归的目标是最小化损失函数，它由两部分组成：一部分是普通最小二乘法的残差平方和，另一部分是正则化项（岭项）。

②正则化项：岭项是系数的平方和与一个正则化参数的乘积，这个参数通常表示为λ。通过调节λ的大小，可以控制正则化的强度。当λ为0时，岭回归退化为普通最小二乘法；当λ趋于无穷大时，所有系数都趋于零，模型变得简单。通过调节正则化参数λ，可以灵活地控制模型的复杂度，避免过拟合。

③解决方案：岭回归的解决方案是通过求解目标函数的最小化来得到。这通常使用矩阵运算来实现，计算效率较高。

2. 计算公式

岭回归的目标是最小化带有岭项的损失函数：

$$\widehat{\beta}^{ridge} = \underset{\beta}{argmin}\left\{\sum_{i=1}^{N}\left(y_i - \beta_0 - \sum_{j=1}^{p} x_{ij}\beta_j\right)^2 + \lambda\sum_{j=1}^{p}\beta_j^2\right\} \tag{4-1}$$

其中，$\sum_{i=1}^{N}\left(y_i - \beta_0 - \sum_{j=1}^{p} x_{ij}\beta_j\right)^2$原来多元线性回归的残差平方和Q（$\beta$），表示观测值和模型预测值之间的差异的平方和。$\lambda\sum_{j=1}^{p}\beta_j^2$是岭项，保证$\beta$不会变得很大。$\lambda$是正则化参数，用于控制正则化的强度。较大的$\lambda$会导致系数趋近于零，从而减小模型的复杂度。

$$\widehat{\beta}^{ridge} = \underset{\beta}{argmin}\sum_{i=1}^{N}\left(y_i - \beta_0 - \sum_{j=1}^{p} x_{ij}\beta_j\right)^2$$

$$\text{subject to } \sum_{j=1}^{p}\beta_j^2 \le t \tag{4-2}$$

第二行是对第一行的一个约束项，也就是说所有系数β平方和应该<某个阈值t。

（七）逐步回归

逐步回归是一种基于迭代优化的模型选择方法，旨在构建一个与目标变量相关性较强且具有解释力的模型。其理论基础涉及几个关键概念和统计学原理：

①模型选择与复杂性控制： 在建立回归模型时，通常可能有很多的自变量可供选择。然而，过多的自变量可能导致模型过拟合，即在训练数据上表现良好，但在新数据上泛化能力差。因此，需要一种方法来选择合适的自变量，并控制模型的复杂性，以平衡拟合度和泛化能力之间的关系。

②目标函数： 在逐步回归中，通常会定义一个目标函数，用于衡量模型的性能。这个目标函数可以是最小化残差平方和（RSS）等，或者是最大化模型的拟合度，比如最大化R方或最大似然估计。

③贪婪算法： 逐步回归通常使用一种贪婪算法，逐步添加或删除变量以优化目标函数。

前向逐步回归：从空模型开始，逐步添加一个自变量，每次选择对模型拟合度有最大贡献的自变量，直到满足某个停止准则.

后向逐步回归：从包含所有自变量的模型开始，逐步删除一个自变量，每次选择对模型拟合度影响最小的自变量，直到满足停止准则。

④模型选择准则： 在逐步回归中，需要定义一种停止准则，以确定何时停止迭代并选择最终模型。常用的停止准则包括AIC（赤池信息准则）、BIC（贝叶斯信息准则）、交叉验证等，这些准则通常考虑模型的拟合度和复杂性之间的权衡。

⑤正则化技术： 在逐步回归中，还可以应用正则化技术，如岭回归（Ridge Regression）或Lasso回归（Least Absolute Shrinkage and Selection Operator），以进一步控制模型的复杂性。

总的来说，逐步回归方法通过迭代地调整模型，逐步优化模型的性能和复杂性，从而构建一个简洁而又具有较好预测能力的回归模型。

三．铁路客运量影响因素指标的选取和量化

（一）指标选取

依据在各种实际情况下的铁路客运量历年数据和生活常识，我们选取了第三产业GDP(现价)，国内城镇居民旅游人数，交通运输、仓储和邮政业GDP(现价)，国民总收入，城镇单位就业人员平均工资，铁路旅客运输平均运距，国家铁路营业里程，铁路旅客周转量等因子作为待选取指标（2008-2021铁路客运量待选取指标实际数据表见附录）。

通过灰色关联分析探测铁路客运量与这些指标的关联程度并排序，得到下表。该关联程度反应了这些指标对铁路客运量的影响大小，我们选取了关联程度为0.628932 及以上的因子——高速铁路营业里程，铁路客车拥有量（软座车），第三产业GDP(现价)，铁路客车拥有量（软卧车），铁路旅客周转量，铁路客车拥有量（硬座车），交通运输、仓储和邮政业GDP(现价)，城镇单位就业人员平均工资，作为分析指标来进行后续计算，以得出这些指标与客运量的具体关系。

表1 影响指标与铁路客运量关联程度

高速铁路营业里程:年	0.805706
铁路客车拥有量:软座车:年	0.724653

GDP(现价):第三产业:年	0.695438
铁路客车拥有量:软卧车:年	0.657567
铁路旅客周转量:年	0.648669
铁路客车拥有量:硬座车:年	0.648509
GDP(现价):交通运输、仓储和邮政业:年	0.637473
城镇单位就业人员平均工资:年	0.628932
国民总收入:年	0.620927
外出农民工人数:年	0.617425
国内城镇居民旅游人数:年	0.612934
煤炭中间消费量:发电:年	0.612625
铁路旅客运输平均运距:年	0.612582
高速铁路旅客周转量:年	0.612361
高速铁路旅客周转量占铁路旅客周转量的比重:年	0.612361
流动人口数:年	0.612361
国家铁路营业里程:年	0.61236
民用航空港澳台地区航线数:年	0.61236
高速铁路营业里程占铁路营业里程的比重:年	0.61236
高速铁路旅客周转量占铁路旅客周转量的比重:年	0.61236
铁路客车拥有量:硬卧车:年	0.609275
可供消费的电量:年	0.601178
人口数:抽样数:住本乡镇街道,户口在外地且离开户口登记地半年以上:年	0.598107

（二）数据预处理

为避免异方差的影响，我们对已选取的这些指标进行预处理，先对其进行去量纲化，再取对数处理，以此增强数据的稳定性。

因选取指标具有不同的量纲和数值范围，例如，某些因子可能是时间（年份），而另一些可能是货运量或人口数量。去量纲化可以将这些因子统一为相同的标准，使得它们可以进行比较和分析。同时选取指标的数据可能存在很大的差异性，去量纲化可以将这些差异性降低到一定程度，使得数据更易于处理和分析。

取对数处理可以将数据的指数关系转化为线性关系，这样更容易进行统计分析和建立数学模型。在铁路客运量的研究中，存在影响因子与客运量之间的非线性关系，通过取对数可以更好地探索这种关系。同时量纲化和取对数处理可以一定程度上减少异常值的影响，使得数据更加稳定，减小量纲和数据范围的影响。

表2 选取指标预处理后的数据

时间	GDP(现价):第三产业:年	GDP(现价):交通运输、仓储和邮政业:年	城镇单位就业人员平均工资:年	铁路旅客周转量:年
2021	1.502049314	1.084691102	1.30753192	0.207027698
2020	1.394779201	0.908044424	1.214838193	0.06079664
2019	1.364238661	0.953408528	1.141588512	0.636922216
2018	1.27507323	0.901973424	1.047970803	0.598096111
2017	1.164309959	0.818904541	0.944580795	0.548116537
2016	1.049546433	0.702074831	0.849376909	0.480675108
2015	0.938482031	0.623064145	0.763829629	0.430241309
2014	0.819958348	0.55580888	0.667987298	0.368266457
2013	0.708840627	0.464433982	0.577479268	0.309063611
2012	0.581950013	0.372838095	0.481448202	0.232262508
2011	0.457129277	0.288531366	0.369100027	0.211665898
2010	0.2856254	0.137683296	0.234607795	0.119067574
2009	0.123187291	0.009415681	0.109559591	0.012809876
2008	0	0	0	0
时间	铁路客车拥有量:软卧车:年	铁路客车拥有量:软座车:年	铁路客车拥有量:硬座车:年	高速铁路营业里程:年
2021	0.336513381	2.726710783	-0.085848443	4.090598338
2020	0.342256987	2.670142398	-0.064406326	4.033957386
2019	0.332390514	2.604528452	-0.047817139	3.96462252
2018	0.324718107	2.498576787	0.004556636	3.796226826
2017	0.355262657	2.386689583	0.030886374	3.623647717
2016	0.365306936	2.281058311	0.072707694	3.532865535

2015	0.355262657	2.122570386	0.081885388	3.385840553
2014	0.303044455	1.757090614	0.015799059	3.198931415
2013	0.264665761	1.614912723	0.047298184	2.798678756
2012	0.216439099	1.147259713	0.075497719	2.634259112
2011	0.167231311	0.794120424	0.091089344	2.285462416
2010	0.159157873	0.606178826	0.075943402	2.034009471
2009	0.135545492	0.208555887	0.075051838	1.391011439
2008	0	0	0	0

（三）因果检验

数据预处理后，我们对已选取的铁路客运量影响因素指标的历年数据，通过格兰杰因果检验模型进行一个因果检验。然而，我们注意到格兰杰因果模型在应用时存在一定挑战，因为其模型复杂度较高，需要大量数据支持以避免过拟合的问题。由于我们的数据集规模较小，导致模型可能过于学习每一个数据的特征，从而导致拟合效果过于完美。

```
    raise InfeasibleTestError(
statsmodels.tools.sm_exceptions.InfeasibleTestError: The Granger causality test statistic cannot be compute because the VAR has a perfect fit of the data.
```

图3 格兰杰因果检验下的过拟合状态

由图可见，这个错误提示说明 VAR 模型对数据拟合得非常完美，因此无法计算格兰杰检验统计量。我们由此推测出以下原因：

①数据过度拟合：若数据非常适合VAR模型，模型可能会完美地拟合数据，导致无法进行格兰杰检验。这意味着我们的数据本身就不适合用于此类因果分析，或者需要更严格地控制模型的复杂度。

②数据质量问题：数据中可能存在异常值、缺失值或其他问题，导致 VAR 模型拟合得过于完美。在这种情况下，需要对数据进行清洗和预处理，以确保模型的稳健性。

③样本量不足： 若样本量太小，可能会导致模型过度拟合数据。这种情况下需要更多的数据来进行可靠的因果分析。

（四）稳定性检验

为了验证数据的稳定性，我们采用了ADF检验法，以确定这些数据是否服从一阶单整（差分后是稳定的）。通过这些检验结果，我们对每个序列进行了单独

的分析。ADF检验的零假设是序列具有单位根，即非稳定。在此基础上，我们观察每个检验统计量，并将其与临界值进行比较。例如，对于显著性水平为5%的情况，若检验统计量小于对应的临界值，我们将接受零假设，即认为序列是稳定的。而若在1%的显著性水平下，检验统计量大于对应的临界值，则拒绝零假设，认为序列是非稳定的。

```
客运量: (-4.0507311988367745, 0.0011669658998409828, 0, 12, {'1%': -4.137829282407408, '5%': -3.1549724074074077, '10%': -2.7144769444444443}, -29.732850819412427)
GDP(现价)第三产业 一阶单整:
(-2.533350919477768, 0.10756909214542099, 4, 8, {'1%': -4.6651863281249994, '5%': -3.3671868750000002, '10%': -2.802960625}, -40.870802620108115)

交通运输、仓储和邮政业 一阶单整:
(-3.3560150067814507, 0.012552886054888801, 1, 11, {'1%': -4.223238279489106, '5%': -3.189368925619835, '10%': -2.729839421487603}, -28.79052920026357)

城镇单位就业人员平均工资 一阶单整:
(-2.187698994174767, 0.21074026613563185, 1, 11, {'1%': -4.223238279489106, '5%': -3.189368925619835, '10%': -2.729839421487603}, -45.147460837202466)

铁路旅客周转量 一阶单整:
(-2.418872720451558, 0.13648041729907023, 4, 8, {'1%': -4.6651863281249994, '5%': -3.3671868750000002, '10%': -2.802960625}, -37.51066122248161)

软卧车拥有量 一阶单整:
(-0.7761789856386823, 0.8260193714963777, 0, 12, {'1%': -4.137829282407408, '5%': -3.1549724074074077, '10%': -2.7144769444444443}, -25.783701096346277)

软座车拥有量 一阶单整:
(-1.9154854406823794, 0.32481170310354895, 4, 8, {'1%': -4.6651863281249994, '5%': -3.3671868750000002, '10%': -2.802960625}, -8.687174394104176)

硬座车拥有量 一阶单整:
(-2.066364086124268, 0.2582530195508164, 0, 12, {'1%': -4.137829282407408, '5%': -3.1549724074074077, '10%': -2.7144769444444443}, -25.573198523950794)

高速铁路营业里程 一阶单整:
(3.932433035423786, 1.0, 4, 8, {'1%': -4.6651863281249994, '5%': -3.3671868750000002, '10%': -2.802960625}, -5.204750693720605)
```

图4 针对每个数据序列的稳定性检验结果

针对每个数据序列，我们进行了详尽的分析，得出了哪些序列相对较为稳定，哪些序列相对较为不稳定的结论。

交通运输、仓储和邮政业GDP(现价):在显著性水平为1%的情况下非稳定，在5%和10%的情况下稳定。

第三产业GDP(现价)，城镇单位就业人员平均工资，铁路旅客周转量，铁路客车拥有量（软卧车），铁路客车拥有量（软座车），铁路客车拥有量（硬座车），高速铁路营业里程:在显著性水平为1%，5%，10%的情况下都非稳定。

针对数据稳定性较低的情况，我们对数据进行了四次差分。其中，客运量，铁路客车拥有量（软座车）和城镇单位就业人员平均工资在一次差分后显著性水平为1%，5%，10%的情况下都已稳定，铁路旅客周转量在一次差分后显著性水平为5%，10%的情况下都已稳定；

铁路客车拥有量（硬座车）在两次差分后显著性水平为5%，10%的情况下都已稳定，铁路客车拥有量（软卧车）在三次差分后显著性水平为5%，10%的情况下都已稳定，高速铁路营业里程在四次差分后显著性水平为5%，10%的情况下都已稳定。

经过ADF检验，我们不难看出这八个变量除交通运输、仓储和邮政业GDP(现价)外都要经过n阶差分才能稳定，而这也符合我们的预期。因为从变量的数据可以直观地发现，这些变量大多具有平稳性，而非稳定性，即大多拥有平稳的上升趋势，而不是稳定地分布在一个值附近，这也与我国高质量发展的时代背景相符。针对变量的平稳性，我们选取了基于向量回归、岭回归和逐步回归三个模型进行关联模型的建立。

四. 铁路客运量影响因素的关联模型建立

（一）基于支持向量回归的关联模型

建模步骤:

①导入必要的库：导入了 pandas 用于数据处理，numpy 用于数值计算，matplotlib.pyplot 用于可视化，以及 scikit-learn 中的 SVR 模型、数据预处理工具和模型评估指标。

②读取数据：使用 pandas 从 Excel 文件中读取数据，其中假设数据的最后一列是因变量（目标变量），而其他列是自变量（特征）。

③数据预处理：将自变量和因变量分别存储在 X 和 Y 中，并使用 StandardScaler 进行数据标准化，即：

```
scaler = StandardScaler()
X_scaled = scaler.fit_transform(X)
Y_scaled = scaler.fit_transform(Y.reshape(-1, 1)).ravel()
```

这一步可以使得数据的均值为 0,方差为 1。同时我们分两种情况进行处理，第一种情况中，为了便于预测和比较，我们将数据分成训练集和测试集4:1的比例进行拟合。第二种情况，为了得到整体的拟合图像，我们将所有数据同时作为训练集和测试集进行拟合。

④构建SVR模型：使用 SVR 模型构建一个支持向量回归（SVR）模型，我们根据数据的分布选择了高斯径向基核函数（svr_model = SVR(kernel='poly', degree=3)）并指定了多项式的次数为 3。

在支持向量回归（SVR）中运用高斯径向基核函数，参数C、epsilon和degree对模型的性能和复杂性有重要影响：

C：C是SVR的正则化参数，控制了模型的复杂度和对训练集的拟合程度。较大的C值会导致模型更关注训练数据，可能导致过拟合，而较小的C值则会更强调对误差的惩罚，可能导致欠拟合。C越大，模型对训练数据的适应程度越高，但也可能增加测试数据的误差。

Epsilon：epsilon是SVR的容错参数，控制了在边界上的损失函数的容忍度。它定义了在训练模型时所允许的最大误差范围。较大的epsilon值允许更多的误差，使模型更灵活，而较小的epsilon值会使模型更加严格，更加关注边界上的点。

Degree：degree是多项式核函数的次数。在这个例子中，我们使用的是3次多项式核函数，即degree=3。这决定了核函数的复杂度。较高的次数可以捕捉更复杂的模式，但也会增加过拟合的风险。选择适当的次数需要在模型性能和复杂度之间进行权衡。

这些参数通常需要通过交叉验证等技术进行调优，以获得最佳的模型性能和泛化能力。

为了寻找这些参数的最优值，我们使用了网格搜索法（Grid Search），即一种通过在给定的超参数空间中进行穷举搜索来寻找最佳超参数组合的方法。对于每个超参数的可能取值组合，网格搜索会使用交叉验证来评估模型的性能，并选择在验证集上性能最佳的超参数组合。以下为我们选择的最优参数：

```
Model Parameters:
- C: 1.0
- Epsilon: 0.1
- Degree: 3
```

⑤模型训练和预测：使用拟合后的 SVR 模型对标准化后的自变量 X_scaled 进行预测，得到了预测值 Y_pred。

⑥模型评估：计算预测值与真实值之间的均方误差（Mean Squared Error，MSE），该指标用于评估模型的预测性能，MSE 越小表示模型的预测效果越好。

⑥输出模型参数：输出了 SVR 模型的参数，包括 C（正则化参数）、epsilon（SVR 模型中的松弛变量）、degree（多项式核函数的次数）等。

⑦可视化结果：使用 matplotlib.pyplot 绘制预测值与真实值之间的散点

图，并在同一图中画出了一条直线，代表理想情况下预测值等于真实值的情况。通过观察散点图，可以直观地评估模型的拟合效果。

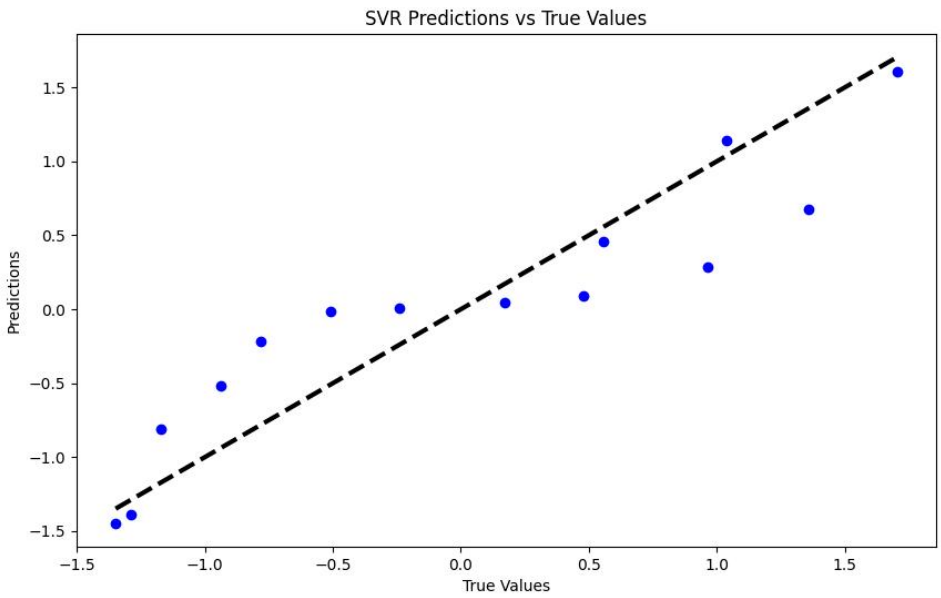

图5 将所有数据作为训练集的拟合效果散点图

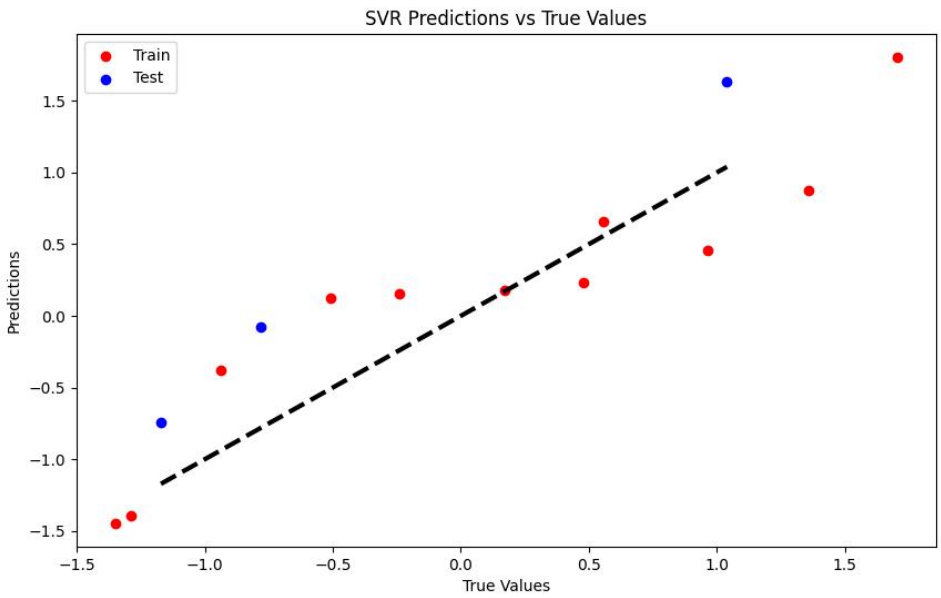

图6 将数据按4:1分成训练集和测试集的拟合效果散点图

我们运用MAPE,MSE（计算预测值与真实值之间的均方误差）两种误差衡量方法得到，将数据分成训练集和测试集4:1的比例进行拟合时，训练集拟合偏差MSE

训练集为0.1319736721806497，测试集为0.348502982408527。MAPE值为8.637940162149597 。而将所有数据作为训练集时，MSE为0.132214666097694。

```
Train Mean Squared Error: 0.1319736721806497
Test Mean Squared Error: 0.348502982408527
```

图7 将数据按4:1分成训练集和测试集的拟合偏差计算值

```
Train Mean Squared Error: 0.132214666097694
Test Mean Squared Error: 0.132214666097694
```

图8 将所有数据作为训练集的拟合偏差计算值

（二）基于岭回归的关联模型

建模步骤:

①首先，我们对数据进行了去量纲化和对数变换处理，将其准备为数据集和训练集。随后对数据进行了标准化，以确保其符合标准的统计特性。数据标准化是一种常见的数据预处理技术，旨在将不同变量之间的值范围统一或调整为相似的尺度，我们选择了StandardScaler标准化方法，该方法是基于Z-score的标准化方法:

特征工程 - 标准化

```
transfer = StandardScaler()
x_train = transfer.fit_transform(x_train)
x_test = transfer.fit_transform(x_test)
```

具体步骤如下：

计算均值和标准差： 对于每个特征（变量），首先计算训练集中该特征的均值和标准差。

应用标准化公式： 对于每个特征，在训练集中减去其均值，然后除以其标准差，从而将其转换为均值为0、标准差为1的标准正态分布（Z-score分布）。

对测试集应用相同的变换： 使用训练集中计算得到的均值和标准差对测试集进行相同的标准化变换。这确保了测试集的数据也按照相同的标准进行了转换，从而保持了数据的一致性。

综上所述，这段代码通过StandardScaler方法对训练集和测试集进行了

Z-score标准化，以确保它们具有相似的尺度和分布特征。

②在数据预处理完成后，我们引入了相应的库，并调用了其中的两个方法，用于执行岭回归处理。方法如下：

```
estimator = Ridge(alpha=1) # 法1
# estimator = RidgeCV(alphas=(0.1, 1, 10))  # 法2
estimator.fit(x_train, y_train)
```

③随后，我们得到了如下结果：首先是拟合图，展示了数据点与拟合曲线的关系。

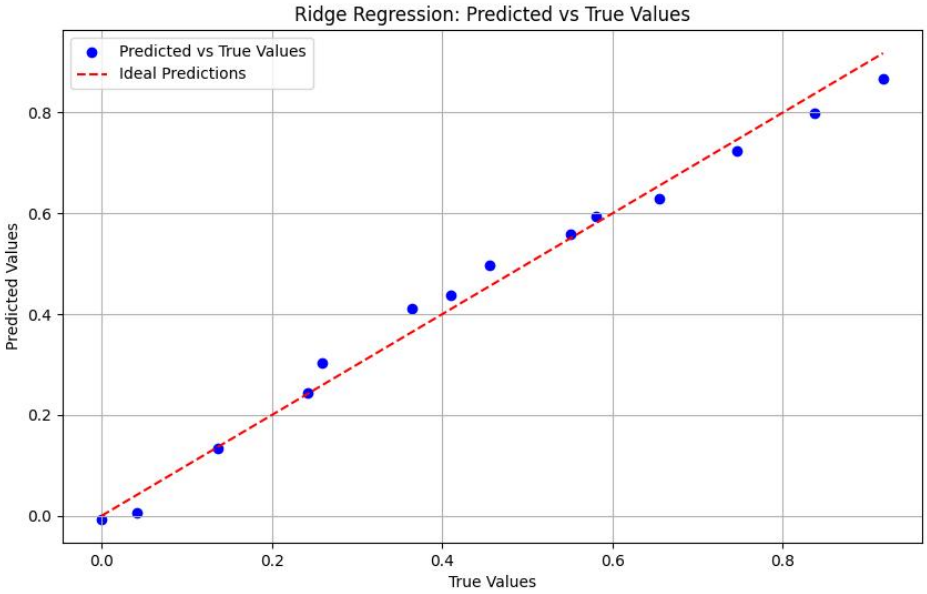

图9 岭回归下真实值与预测值拟合图

这张图显示了真实目标值与模型预测值之间的关系。每个点代表一个样本，横坐标是真实目标值，纵坐标是模型预测值。理想情况下，所有点都应该落在红色虚线所代表的对角线上，表示预测值与真实值完全相等。

其次是MSE误差图，其中包含了偏置项以及底部的误差值，用于评估模型性能。以上述方法对数据进行了回归处理，并产生了相应结果。

```
预测值为:
 [ 0.5931356   0.43836303  0.86628585  0.79803978  0.72446733  0.62847691
  0.55889006  0.49682598  0.41176225  0.3033657   0.24462224  0.13323252
  0.0058352  -0.00735093]
模型中的系数为:
 [ 0.03595163  0.04067262  0.03045852  0.15743571  0.00385426  0.02414067
 -0.01737634 -0.00214765]
模型中的偏置为:
 0.4425679660455701
误差为:
 0.0009741622234577939
```

图10 岭回归下MSE误差图

其中，“预测值”是模型对测试数据集中每个样本的预测。它显示了模型对于给定输入特征的预测结果。

“模型中的系数”是岭回归模型学习到的系数（或权重）。每个系数对应于输入特征的权重，它们表示特征对目标变量的影响程度。如果某个系数的值很大，那么相应的特征在预测中的影响也较大。

“模型中的偏置”是岭回归模型学习到的偏置项（或截距）。偏置是一个常数，表示当所有特征都为零时，预测值与实际值之间的偏移量。

“误差”是模型的均方误差（Mean Squared Error，MSE）。均方误差是模型预测值与真实值之间差异的平方的平均值。它是评估模型性能的常用指标，数值越小表示模型的预测性能越好。

（三）基于逐步回归的关联模型

建模步骤:

①初始化模型（初始所有特征都被选择）

```
selected_features = list(X.columns)
best_model = None
best_aic = float("inf")
```

②开始前向逐步回归或后向逐步回归

前向逐步回归：`for k in range(1, len(X.columns) + 1):  # 从一个自变量开始，逐步增加`

后向逐步回归：for k in range(len(X.columns), 0, -1): # 从所有自变量开始，逐步减少

③添加截距项

```
X_subset = sm.add_constant(X_subset)
```

④拟合模型

```
model = sm.OLS(y, X_subset).fit()
```

⑤计算AIC

```
aic = model.aic
```

⑥更新最佳模型，计算并输出模型参数

```
best_model.params
```

⑦计算并输出MSE下的误差

```
y_pred = best_model.predict(sm.add_constant(X[selected_features]))
mse = mean_squared_error(y, y_pred)
```

```
Selected features: ['交通运输、仓储和邮政业', '城镇单位就业人员平均工资', '铁路旅客周转量', '软卧车拥有量', '软座车拥有量', '高速铁路营业里程']
Best model AIC: -66.71819168012988

                            OLS Regression Results
==============================================================================
Dep. Variable:                   客运量   R-squared:                       0.998
Model:                            OLS   Adj. R-squared:                  0.996
Method:                 Least Squares   F-statistic:                     489.5
Date:                Mon, 13 May 2024   Prob (F-statistic):           8.08e-09
Time:                        23:39:19   Log-Likelihood:                 40.359
No. Observations:                  14   AIC:                            -66.72
Df Residuals:                       7   BIC:                            -62.24
Df Model:                           6
Covariance Type:            nonrobust
==============================================================================
                   coef    std err          t      P>|t|      [0.025      0.975]
------------------------------------------------------------------------------
const            0.0023      0.019      0.123      0.906      -0.042       0.047
交通运输、仓储和邮政业      -0.5775      0.269     -2.143      0.069      -1.215       0.060
城镇单位就业人员平均工资      1.4052      0.283      4.958      0.002       0.735       2.075
铁路旅客周转量           1.0925      0.069     15.770      0.000       0.929       1.256
软卧车拥有量            0.7750      0.395      1.963      0.090      -0.159       1.709
软座车拥有量           -0.2134      0.083     -2.560      0.038      -0.410      -0.016
高速铁路营业里程         -0.1326      0.033     -3.961      0.005      -0.212      -0.053
==============================================================================
Omnibus:                        3.010   Durbin-Watson:                   1.816
Prob(Omnibus):                  0.222   Jarque-Bera (JB):                0.824
Skew:                          -0.126   Prob(JB):                        0.662
Kurtosis:                       4.162   Cond. No.                         332.
==============================================================================
```

图11 最佳模型

```
Notes:
[1] Standard Errors assume that the covariance matrix of the errors is correctly specified.
Model parameters:
const            0.002308
交通运输、仓储和邮政业      -0.577469
城镇单位就业人员平均工资      1.405227
铁路旅客周转量           1.092489
软卧车拥有量            0.775014
软座车拥有量           -0.213362
高速铁路营业里程         -0.132641
dtype: float64
Mean Squared Error (MSE): 0.00018346948723050872
```

图12 最佳模型下特征量对应模型参数及误差结果（MSE）

$$Y = -0.577469x_1 + 1.405227x_2 + 1.092489x_3 + 0.775014x_4 - 0.213362x_5 - 0.132641x_6 + 0.002308$$

如上为我们通过逐步回归得到的铁路客运量计算公式，其中x_1为交通运输、仓储和邮政业GDP(现价)，x_2为城镇单位就业人员平均工资，x_3为铁路旅客周转量，x_4为铁路客车拥有量（软卧车），x_5为铁路客车拥有量（软座车），x_6为高速铁路营业里程。

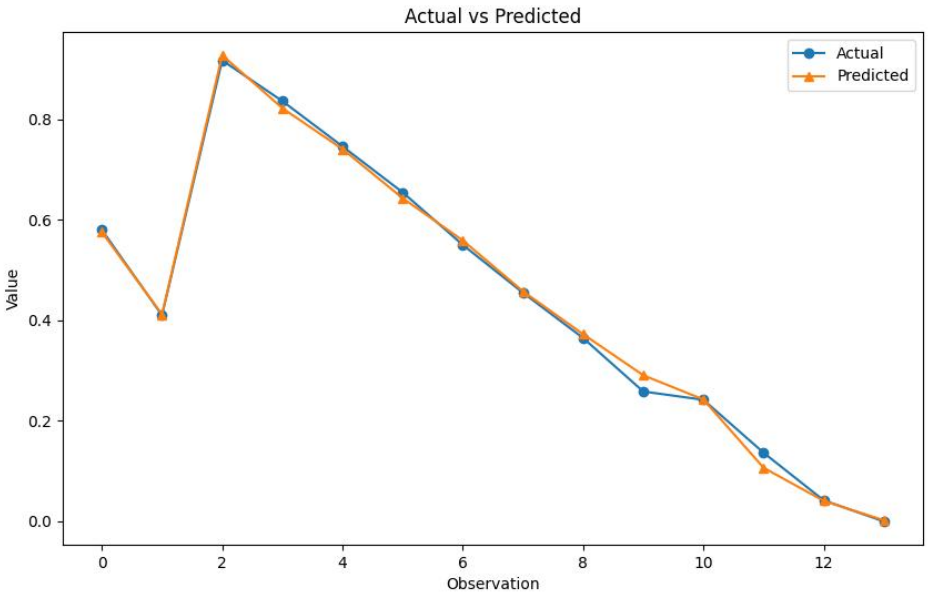

图13 前向逐步回归真实值与预测值拟合图

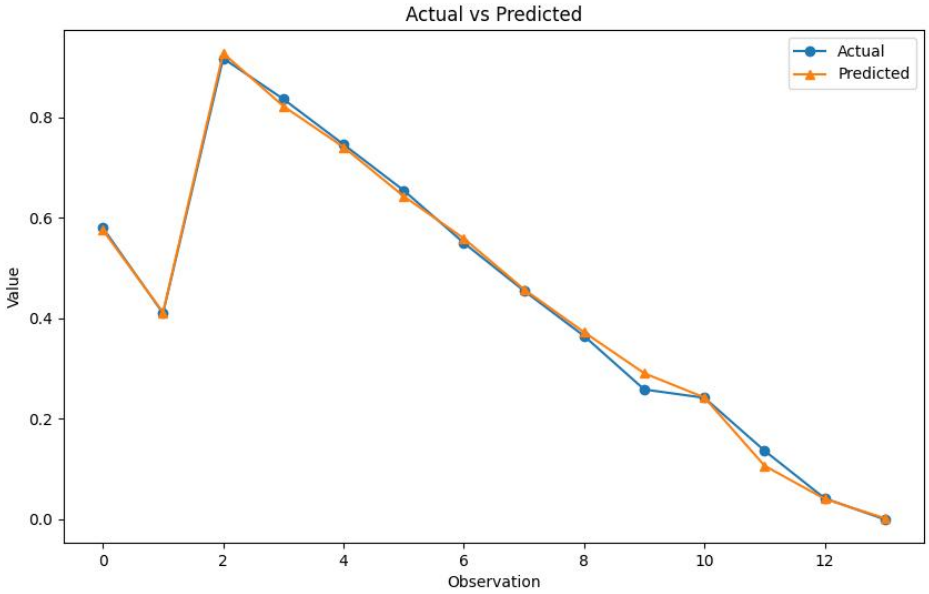

图14 后向逐步回归真实值与预测值拟合图

（四）关联模型的总结分析

表3 三种回归模型的误差对比表（MSE）

回归模型	MSE
支持向量回归	0.132214666097694
岭回归	0.0009741622234577939
逐步回归	0.00018346948723050872

MSE越小，说明数据拟合越好，我们根据MSE结果得出：逐步回归模型拟合精度高，零回归其次，支持向量回归拟合精度最低。

在进行逐步回归分析时，我们注意到一些变量的整体特征，从而在模型中舍弃了部分特征度较低的变量，具体包括铁路客车拥有量（硬座车）和第三产业GDP。这一决策主要基于拟合程度和误差的最小化原则。我们观察到，相较于其他变量，铁路客车拥有量（硬座车）和第三产业GDP与铁路客运量之间的因果性较弱。因此，在考虑向量回归模型时，我们注意到该模型要求时间序列具有较强的因果性，而这些变量的拟合程度较差。

综上所述，在研究铁路客运量影响因素的拟合模型中，由于变量数量多且因果性无法确保，我们首选了逐步回归模型。该模型能够自主选择最佳的自变量，因此被选定为最佳的拟合模型。逐步回归模型的拟合结果显示，铁路客运量与城镇单位就业人员平均工资、铁路旅客周转量、铁路客车拥有量以及交通运输、仓

储和邮政业GDP(现价)相关，而与软座车和高速铁路营业里程则不明显相关。同时，在这些因素中，城镇单位就业人员平均工资和铁路客车拥有量对铁路客运量的影响最为显著。

五．铁路发展建议

根据逐步回归得到的铁路客运量计算公式，我们提出了以下建议以促进中国铁路建设：

提高城镇单位就业人员平均工资：由于其系数为正，增加城镇单位就业人员的平均工资可能会提高铁路客运量。这表明更高的工资水平可能会提高人们的消费能力，从而增加铁路出行的需求。随着中国经济的持续增长和城市化进程的推进，提高城镇单位就业人员的平均工资已经成为政府关注的重点之一。通过提高工资水平，不仅可以提高消费能力，刺激居民消费，也有助于改善劳动力供给结构，吸引更多人才从事高附加值行业，从而间接促进铁路客运需求的增长。

关注铁路旅客周转量：近年来，中国铁路不断提升运输效率和服务水平，通过推行互联网+、智能化等技术手段，提高了旅客出行的便捷性和舒适度。在疫情防控期间，铁路部门加强了卫生保障和安全措施，为旅客提供了更安全、可靠的出行选择。中国铁路建设应该注重提高运输效率和服务质量，以增加旅客周转量，并吸引更多的乘客选择铁路出行。

增加软卧车的数量：其系数均为正，表明增加软卧车和软座车的数量可能会提高铁路客运量。随着生活水平的提高和人们对出行舒适度的追求，软卧车和软座车的需求逐渐增加。特别是在长途夜间列车上，软卧车成为了许多旅客的首选。因此，增加这两种类型车辆的配备，不仅可以提高客运服务的舒适度和便利性，还能够满足不同类型乘客的需求。因此，中国铁路建设可以考虑增加这两种类型车辆的配备，以提升铁路客运的竞争力和吸引力。

而软座的系数是负的，表明增加软座车的数量可能会对铁路客运量产生负面影响。这可能表明在当前情况下，软座车的供给已经超过了需求，增加数量可能会导致座位利用率下降，从而影响铁路客运量。因此，在这种情况下，中国铁路建设部门可能需要重新评估软座车的配置策略，以更好地满足旅客的需求，提高客运服务的效率和质量。

铁路营业里程系数为负，一方面说明我国的铁路覆盖率在不断提高，并且不断向经济并没有很发达的地区延伸，体现了党和国家的温情所在，争取让全国各地的人民都能够通过铁路便利出行；另一方面说明我国铁路网络不断密集，使得各地间更加互通有无，提高了人民出行的效率。因此，即使该因素为负，但其发展与铁路密不可分，中国铁路仍然需要发展铁路网络，提高人民铁路出行的覆盖率与效率。

综上所述，中国铁路建设可以通过优化运输服务、提高运输效率、加强基础设施建设等手段来促进铁路发展。

六．反思

我们的研究仍存在以下不足：

1.数据库中的大部分数据存在年份残缺，导致获取的多变量公共年份数据过少，难以支持应用格兰杰因果检验等复杂模型。同时，受数据量限制，无法使用差分后的数据作为模型样本，只能采用对数处理、标准化等数据处理方法。

2.选取的数据年份较为陈旧，仅截止至2021年，对未来的预测能力较差。

3.最终选取的变量较少，仅包括八个，并且主要集中在铁路行业和经济领域，缺乏全面性。

4.选取的拟合模型相对单一，偏向处理平稳性数据，应引入向量误差修正模型等更适用于非平稳性数据的模型进行更全面的比较分析。

5.选取的拟合模型均倾向于进行线性拟合，应引入多项式回归等非线性拟合模型进行更全面的比较分析。

6.目前研究以年为单位进行，可以在考虑月份差异的情况下以月为单位进行进一步研究分析。

7.研究目前主要聚焦于全国整体铁路客运量，可以将全国铁路客运量的关联模型应用于具体地区，以展示该地区铁路客运量及其影响因素与全国铁路客运量及其影响因素的差异，并展开进一步研究。

参考文献

[1]杨飞,贾俊芳,刘岩岩,等.基于Newton插值与超松弛技术的铁路客运量预测研究[J].铁道运输与经济,2023,45(03):44-52.DOI:10.16668/j.cnki.issn.1003-1421.2023.03.07.

[2]蒋祥. 基于格兰杰因果关系的数学天分青少年脑网络研究[D].东南大学,2023.DOI:10.27014/d.cnki.gdnau.2021.004580.

[3]孔德越,程默,颜颖,等.基于铁路旅客常住地与行程环的年度出行特征分析体系[J].中国铁道科学,2022,43(05):132-145.

[4]肖尧,刘斌,杨浩.铁路客运需求分析与短期客流预测[J].科学技术与工程,2022,22(09):3727-3734.

[5]兰菁.福建省铁路客运可达性及经济联系格局研究[C]//中国城市规划学会,成都市人民政府.面向高质量发展的空间治理——2020中国城市规划年会论文集（14 区域规划与城市经济）.南京大学建筑与城市规划学院;,2021:8.DOI:10.26914/c.cnkihy.2021.036147.

[6]金霞,雷桂荣.客运交通网络特征与城市宏观经济水平的关系研究[C]//中国城市规划学会,成都市人民政府.面向高质量发展的空间治理——2020 中国城市规划年会论文集（14 区域规划与城市经济）.南京市城市与交通规划设计研究院股份有限公司;,2021:10.DOI:10.26914/c.cnkihy.2021.036183.

[7]李静怡.铁路客运量影响因素实证分析与需求预测[D].河北经贸大学,2021.DOI:10.27106/d.cnki.ghbju.2021.000527.

[8]刘罗曼.时间序列平稳性检验[J].沈阳师范大学学报(自然科学版),2010,28(03):357-359.

[9]许欢,李青,夏道明,等.基于改进支持向量回归模型的高校学生成绩预测研究[J].鄂州大学学报,2024,31(01):102-105.DOI:10.16732/j.cnki.jeu.2024.01.036.

[10]刘天彪,徐懿凡,杨斌,等.基于时间序列的中超联赛球队竞技表现稳定性分析[J].武汉体育学院学报,2019,53(11):87-94.DOI:10.15930/j.cnki.wtxb.2019.11.013.

[11]曹云辉.带有时变参数时间序列模型的方差稳定性检验[D].山东大学,2018.

[12]张博,胡晓敏,岳凯,贺路尧.浅谈提升我国铁路客运量的新方法[J].黑龙江交通,2020,43(06):250-251.
[13]陈芳英.安徽省高铁对产业结构影响研究——基于灰色预测模型[J].景德镇学院学报,2020,35(03): 69-73.
[14]朱雷鹏,钱勇生,曾俊伟,广晓平.西部地区综合交通一体化与新型城镇化动态协调发展研究[J/OL]. 公路,2021(03):180-186[2021-03-16].
[15]张艳,徐琴.信用结构、信用规模与经济增长——基于 TVP-VAR 模型的实证检榎[J].吉林工商学院学报,2020,36(06):54-60.
[16]王雷,金勇,刘岩.铁路客运量预测模型对比分析[J].山东交通学院学报,2020,28(03):25-32+47.
[17]张鹏,张海燕.基于EMD 和 SVM 的铁路客运量分析研究[J].山西大同大学学报(自然科学版),2021, 37(01):50-54.
[18]李鹏飞,张瑞.基于TSCI变动的RBF-SVR月度快递业务量分析及预测[J/OL].统计与决策,2021(05): 184-188
[19]单义明,杨侃.基于灰色关联度分析的山西省 PSO-SVR 需水量预测模型[J].水电能源科学,2021,39 (02):18-21.
[20]杨国华,颜艳,杨慧中.GM(1,1)灰色预测模型的改进与应用[J].南京理工大学学报,2020,44(05):572-5 82.
[21]宋鹏,张淼.国债收益率预测的 VAR-LSTM 框架[J/OL].统计与决策,2021(05):148-152
[22]李珊珊,刘越.基于 Matlab 的逐步回归分析在体育研究中的应用[J].长春大学学报,2020,30(12):25- 30.
[23]颜丙峰,王光耀,朱肖曼,史士东.逐步回归分析中国煤质特性与其液化特性关系[J/OL].石油学报(石油加工),2021(02):362-371
[24]高扬,李雯.东北三省大豆与玉米生产替代关系研究——基于超越对数生产函数的岭回归估计[J]. 价格理论与实践,2020(08):62-66.
[25]王言文,邱启荣,王宝坤.基于 Lasso 和 SVR 的向量夹角余弦变权重组合预测模型[J].统计与决策,2020,36(18):22-26.
[26]Hsieh C, Feng C. The Highway Resilience and Vulnerability in Taiwan[J].

Transport Policy, 2018.
[27]柯文前,陆玉麒,陈伟, 等. 高速交通网络时空结构的阶段性演进及理论模型——以江苏省高速公路交通流网络为例[J]. 地理学报, 2016(02):281-292.
[28]Aschauer D A. Is Public Expenditure Productive[J]. Journal of Monetary Economics, 1989,23(2):177-200.
[29]Esfahani H S, Ramirez M T. Institutions, Infrastructure, and Economic Growth[J]. Journal of DevelopmentEconomics, 2003,70(2):443-477.
[30]吴峰,施其洲. 基于熵值理论的产业结构与交通运输结构关系研究[J]. 交通运输系统工程与信息, 2006(01):71-74.

附录

2008-2021铁路客运量待选取指标实际数据表

时间	GDP(现价):第三产业:年	国内城镇居民旅游人数:年	GDP(现价):交通运输、仓储和邮政业:年	国民总收入:年
2021/12/31 0:00	614476.4472	2342	48423.8748	1141230.783
2020/12/31 0:00	551973.7482	2065	40582.8797	1005451.313
2019/12/31 0:00	535370.9907	4471	42466.2821	983751.2
2018/12/31 0:00	489700.7626	4119	40337.24741	915243.5
2017/12/31 0:00	438355.9474	3677	37121.87476	830945.7
2016/12/31 0:00	390828.06	3195	33028.6941	742694.1
2015/12/31 0:00	349744.65	2802	30519.50589	685571.2
2014/12/31 0:00	310653.9632	2483	28534.41068	644380.2
2013/12/31	277983.54	2186	26042.65	588141.2

0:00	28		716	
2012/12/31 0:00	244856.249	1933	23763.24279	537329
2011/12/31 0:00	216123.621	1687	21841.96758	483392.7947
2010/12/31 0:00	182061.8903	1065	18783.61914	410354.1
2009/12/31 0:00	154765.1146	903	16522.40854	347934.9
2008/12/31 0:00	136827.538	703	16367.56891	321229.5
城镇单位就业人员平均工资:年	铁路旅客运输平均运距:年	国家铁路营业里程:年	铁路旅客周转量:年	客运量:铁路:年
106837	366.343481	150739.34	9.56781E+11	2611705580
97379	375.139235	146330.43	8.26619E+11	2203498974
90501	401.818325	139926.38	1.47066E+12	3660022555
82413	419.164614	131651.29	1.41466E+12	3374946740
74318	436.37554	128604.5	1.34569E	3083793424

	8	05	+12	
67569	447.017045	123070.7963	1.25793E+12	2814052277
62029	471.848491	117537.0875	1.19606E+12	2534840000
56360	487.800486	66989.216	1.12419E+12	2304600000
51483	503.123159	66585.052	1.05956E+12	2105969165
46769	518.247088	66297.876	9.81233E+11	1893368511
41799	516.162609	66049.778	9.61229E+11	1862260728
36539	522.774854	66239.019	8.76218E+11	1676090361
32244	516.813833	65491.2	7.87889E+11	1524511926
28898	532.078324	63974.884	7.7786E+11	1461928479
民用航空港澳台地区航线数:年	煤炭中间消费量:发电:年	可供消费的电量:年	铁路客车拥有量:软卧车:年	铁路客车拥有量:硬卧车:年
25	23348700	8.52001E	4861	19128

	00	+12		
94	21163500 00	7.76202E +12	4889	19093
111	21015900 00	7.48663E +12	4841	19430
100	20519700 00	7.15092E +12	4804	19856
96	19392500 00	6.5914E+ 12	4953	20438
109	18266600 00	6.12044E +12	5003	20683
109	17956800 00	5.80213E +12	4953	20312
114	18952500 00	5.78305E +12	4701	18977
107	19517738 00	5.42041E +12	4524	18018
99	18353099 00	4.97677E +12	4311	17859
91	17557853 00	4.70027E +12	4104	16981
85	15374248	4.19365E	4071	16486

		00	+12		
72		1439672917	3.70327E+12	3976	15249
49		1326523700	3.45408E+12	3472	13975
铁路客车拥有量:软座车:年	铁路客车拥有量:硬座车:年	高速铁路营业里程:年	高速铁路营业里程占铁路营业里程的比重:年	高速铁路旅客周转量:年	高速铁路旅客周转量占铁路旅客周转量的比重:年
32292	15272	40139.347	26.6283	60641567.8	63.3808
30516	15603	37929.005	25.9201	48448658.1	58.6106
28578	15864	35388.3	25.290655	77466687.2	52.674629
25705	16717	29903.8	22.714398	68719101.8	48.576468
22984	17163	25163.8	19.81872	58756011.5	43.662301
20680	17896	22980	18.533469	46410000	36.9
1764	18	19838	16.39905	38634000	32.3

9	061		3		
12246	16906	16456	14.7	28250000	25.1
10623	17447	11028	10.691782	21411000	20.2
6655	17946	9356	9.583563	14461000	14.7
4675	18228	6601	7.078847	10584000	11
3874	17954	5133.4	5.630057	4632000	5.3
2603	17938	2698.7	3.155714	1622000	2.1
2113	16641	671.5	0.842669	156000	0.2
外出农民工人数:年	人口数:抽样数:住本乡镇街道,户口在外地且离开户口登记地半年以上:年		铁路旅客周转量111:年	流动人口数:年	客运量:铁路:全国:年
17172	445361		9.56781E+11	3.8467	261170.558

16959	539144.3125	8.26619E+11	3.7582	220349.8974
17425	240481	1.47066E+12	2.3585	366002.2555
17266	235999	1.41466E+12	2.41	337494.674
17185	219571	1.34569E+12	2.44	308379.3424
16934	209164	1.25793E+12	2.45	281405.2277
16884	4545865	1.19606E+12	2.47	253484
16821	213720	1.12419E+12	2.53	230460
16610	211539	1.05956E+12	2.45	210596.9165
16336	215952	9.81233E+11	2.36	189336.8511
15863	223697	9.61229E+11	2.3	186226.0728
15335	1476977.438	8.76218E+11	2.21	167609.0361

14533	100674	7.87889E+11	2.064175	152451.1926
14041	1664544.063	7.7786E+11	1.91563125	146192.8479